# OpenCL笔记整理

2019年2月28日

1 模型 2

# 1 模型

#### 1.1 平台模型 (Platform Model)

OpenCL将所有计算机的硬件系统进行抽象,并提出以下硬件模型。并用这个模型代表所有的硬件系统。具体模型如下图所示:

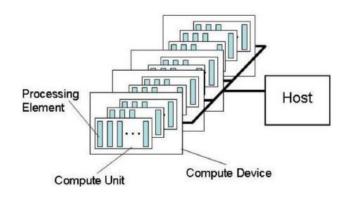


图 1: OpenCL硬件层模型

在实际的计算机系统中, Host 通常是一个CPU 担任, 它负责为其他有计算功能的设备(device)分配任务;

而Compute Device代表计算设备,通常可以是GPU、CPU、DSP等其他芯片。比如可以用一个CPU作Host,而使用GPU作为计算设备。

其中Processing Element 是上述芯片中的一个计算单元。比如对于一个CPU,可能是四核的,而Processing Element 可以代表其中一个核。

而Compute Unit是Processing Element 组成的组。通常,可以根据工作任务将Processing Element 分组,每一组称之为Compute Unit。对于GPU或者FPGA 通常会将Processing Element 分组。

### 1.2 内存模型 (Memory Model)

为了方便数据的存储和共享,OpenCL 将不同硬件平台上的内存结构,抽象成以下的内存模型。 对于Host一般负责任务的分配,所以会有自己的内存。

而Global/Constant Memory是Compute Device 的内存,其中数据所有 计算单元(Processing Element)共享。比如如果计算设备是GPU,该内存 1 模型 3

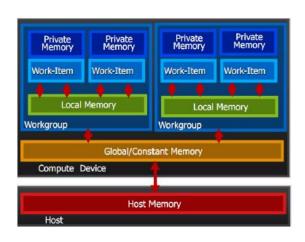


图 2: OpenCL内存模型

就对应GPU 上的内存。

通常对于每个Processing Element (Work-Item)可能会附有私有内存 (Private Memory),一般以缓存方式出现,其中数据由Processing Element 独享。

对于不同硬件平台,可能每一个组(Work Group)又会配有Local Memory,方便数据共享。

#### 1.3 执行模型 (Execution Model)

执行模型即是对编程过程中或运行过程中所用到的环境的抽象。

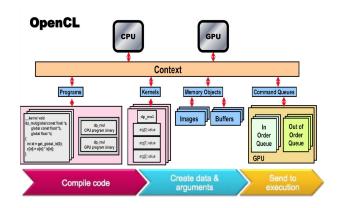


图 3: OpenCL软件模型

1 模型 4

执行模型在编程时可以分两部分,其中kernels 的代码在计算设备中运行; 而host program 在host 中运行。

kernels需要在host配置的context环境内执行。该context 通常会含有:

\*devices opencl 可用的计算设备

kernel objects 可以在计算设备上运行的函数

program objects 可以在kernel 上执行的源码

memory objects host 和计算设备可以使用的数据。buffers: 一块内存; images: 多维内存

如上文所述,对于host program,需要配置context 环境给kernel 使用。host 使用command-queue 与计算设备进行协作。每一个command-queue 与一个计算设备对应。command 可以分为3 种:

kernel-enqueue commands 将命令入队的命令

memory commands 数据交互的命令

synchronization commands 用于显式定义同步点

# 2 OpenCL编程

流程:

1. 确定并选择platforms 相关函数: clGetPlatformIDs()/clGetPlatformInfo()

2. 确定并选择devices 相关函数: clGetDeviceIDs()/clGetDeviceInfo()

3. 创建context 相关函数: clCreateContext()

4. 创建command queue 相关函数: clCreateCommandQueue()

5. 读写到device 相关函数: clBuildProgram()/clCreateKernel()/clCreateBUffer()

6. 启动kernel 相关函数: clEnqueueNDRangeKernel()

7. 释放资源(clean up) 相关函数: clRelease\*()

### 2.1 平台获取 (platform)

OpenCL最先要做的是获取平台信息。可以使用下述函数获取平台信息:

函数原型:

cl\_int clGetPlatformIDs (cl\_uint num\_entries, // 平台数 // 平台指针,返回找到的平台 cl\_platform\_id \*platforms, // 返回可用的平台数 cl\_uint \*num\_platforms)

调用样例:

// 获取当前可用平台数

6

```
cl_uint platform_number;
int status = clGetPlatformIDs(0, NULL, &platform_number);
// 根据可用平台数, 分配空间
cl_platform_id* platforms
                  = new cl_platform_id[platform_number];
// 调用函数, 获取platforms
status = clGetPlatformIDs(platform_number, platforms, NULL);
    设备获取 (device)
2.2
   当获取平台信息后,每个平台可能对应有多个设备,接下来要获取设
备信息。设备类型分为CPU,GPU,ACCEGERATOR等,具体参考《The
OpenCL Specification -version
2.0 \!\!\!\rangle -table
4.2
函数原型:
cl_int clGetDeviceIDs(cl_platform_id platform, // 平台信息
                    // 设备类型
                    cl_device_type device_type,
                    // 设备个数
                    cl_uint num_entries,
                    // 设备指针
                    cl_device_id *devices,
                    // 返回设备个数
                    cl_uint *num_devices)
调用样例:
// 获取当前平台的设备
cl_uint device_number;
int status = clGetDeviceIDs(platform[0],
                         CL_DEVICE_TYPE_ALL,
                         Ο,
                         NULL,
                         &device_number);
```

#### 2.3 配置context

接下来需要给某个或多个设备配置相应的contex (环境),即配置相应的资源。以此管理诸如指令队列,内存,源码等信息。

### 2.3.1 声明context对象

函数原型:

```
cl_context clCreateContext(
          // context 特性及其对应的值
          const cl_context_properties *properties,
          // 设备个数
          cl_uint num_devices,
          // 设备指针
          const cl_device_id *devices,
          // 回调函数: 当出现错误时自动调用
          void (CL_CALLBACK *pfn_notify)
                      (const char *errinfo,
                      const void *private_info,
                      size_t cb,
                      void *user_data),
          // 回调函数的参数
          void *user_data,
          // 返回的错误码
```

cl\_int \*errcode\_ret)

其中context特性,可以指定与本context对应的平台以及OpenCL 和其他APIs的同步方式。

#### 调用样例:

// 为第一个device配置contex

#### 2.3.2 配置context 的指令队列(command queue)

声明好context后,需要为其配置指令队列。这是一段内存空间,每个device 的指令都将先保存在这段内存中,再发送给device。

#### 函数原型:

 $\verb|cl_command_queue| clCreateCommandQueueWithProperties(|$ 

// 待配置的context

cl\_context context,

// 声明context 时对应的设备

cl\_device\_id device,

// 指定指令队列的参数

const cl\_queue\_properties \*properties,

8

// 返回的错误码

cl\_int \*errcode\_ret)

#### 调用样例:

#### 2.3.3 配置context 的源码对象(kernel object&program object)

**创建源码对象** 由于异构计算的特殊性,这里需要载入在device中运行的源码并编译成可在异构平台执行的文件。所有操作通过调用相应的函数实现。

编写kernel.cl 就是在device中实际运行的代码。这段代码可以以字符串的形式写在源文件中,也可以单独写成一个.cl 文件。其具体格式与一个C/C++函数类似,只是变量之前要注明限定符。

```
代码举例:
```

**字符串格式的.cl** 如果是以字符串的形式写在源文件中,每行用一个字符串表示,并且要注意换行需要使用转义字符,比如:

代码举例:

源码对象的创建 声明program对象可以使用以下函数:

函数原型:

```
// 字符串长度的数组
const size_t *lengths,
// 错误码
cl_int *errcode_ret)
```

10

其中关于字符串长度的数组,可以设置为NULL,但要求字符串以结束符结尾。否则,要根据实际请设置其中数值。

调用样例:

cl\_program program =
 clCreateProgramWithSource(context,

1, // 字符串数组的个数 &source, // 字符串数组头 NULL, NULL);

编译并链接源码 上文载入源码后,调用本函数进行编译并链接。 (builds = compiles + links)。

函数原型:

void \*user\_data), // 回调函数参数 void \*user\_data) 11

#### 2.3.4 配置context 的内存对象(memory objects)

函数原型:

cl\_mem clCreateBuffer(cl\_context context, // context对象 cl\_mem\_flags flags, // 内存模型 size\_t size, // 内存大小 (bytes) void \*host\_ptr, // 内存指针 cl\_int \*errcode\_ret) // 错误码

其中flags具体可参考《The OpenCL Specification -version2.0》-table5.3

调用样例:

根据table5.3中内容,上述CL\_MEM\_COPY\_HOST\_PTR表示,本函数分配的内存使用buffer\_pointer指向的内容初始化,先分配内存再将指针内容拷贝过去。

根据实际需求,可多次调用上述函数,分配多块内存方便使用。通常可以分配一块输入内存,一块输出内存,分别用于数据的输入(从host-device),和输出。

#### 2.4 配置kernel

声明kernel对象

函数原型:

配置kernel对象参数 即kernel函数的参数,需要调用此函数进行传输。

函数原型:

kernel函数有几个参数,就需要调用几次上述函数。其中参数下标从0开始,一直到n-1。

比如输入参数为上面声明内存对象时,代码举例中的内存对象"buffer":

调用样例:

cl\_int status = clSetKernelArg(kernel, 0,// 参数索引 sizeof(cl\_mem), // 参数尺寸 (void \*)&buffer); // 参数指针

#### 2.5 运行kernel

调用下面的函数, 使命令入队。

函数原型:

cl\_int clEnqueueNDRangeKernel(

// 指令队列对象
cl\_command\_queue command\_queue,
// kernel对象
cl\_kernel kernel,
// 工作维度: 1, 2, 3维

cl\_uint work\_dim,

// 指定各个维度上的起始id。默认为0

const size\_t \*global\_work\_offset,

// 各个维度的尺寸

const size\_t \*global\_work\_size,

const size\_t \*local\_work\_size,

// 指定需要先完成的操作(对象)

cl\_uint num\_events\_in\_wait\_list,

const cl\_event \*event\_wait\_list,

// 返回事件对象

cl\_event \*event)

#### 2.6 读取结果

该操作为读(写)操作,与上述分配内存对象不同。在kernel运行时,可以根据需要读写内存(读写速度可能较慢)。

#### 函数原型:

```
cl_int clEnqueueReadBuffer (
                    // 指令队列对象
                    cl_command_queue command_queue,
                    // 内存对象,用clCreateBuffer()声明
                    cl_mem buffer,
                    // true: 内存读取结束之前,函数不返回
                    // false: 将读取命令入队后即返回
                    cl_bool blocking_read,
                    // 内存读(写)的起始,和尺寸
                    size_t offset,
                    size_t size,
                    // 内存指针,内存读取后,复制到此
                    void *ptr,
                    // 指定需要先完成的操作(对象)
                    cl_uint num_events_in_wait_list,
                    const cl_event *event_wait_list,
                    // 返回事件对象
```

#### cl\_event \*event)

```
cl_int clEnqueueWriteBuffer (
                    // 指令队列对象
                    cl_command_queue command_queue,
                    // 内存对象,用clCreateBuffer()声明
                    cl_mem buffer,
                    // true: 内存读取结束之前,函数不返回
                    // false: 将读取命令入队后即返回
                    cl_bool blocking_read,
                    // 内存读(写)的起始,和尺寸
                    size_t offset,
                    size_t size,
                    // 内存指针,与内存对象声明时一致
                    void *ptr,
                    // 指定需要先完成的操作(对象)
                    cl_uint num_events_in_wait_list,
                    const cl_event *event_wait_list,
                    // 返回事件对象
                    cl_event *event)
调用举例:
cl_int status = clEnqueueReadBuffer(
             // 命令队列
             command_queue,
             // 输出内存对象
             buffer,
             // 内核读取结束之前该函数不会返回
             CL_TRUE,
             0, // 起始位置偏移
             N * sizeof(int), // 内存尺寸, 这里为举例
             // 内存指针
```

buffer\_pointer,

0,
NULL,
NULL);

### 2.7 释放资源

这里需要释放掉上述过程中声明的对象,具体函数原型省略。除了释放OpenCL的对象,也需要释放使用new声明的内存空间,防止内存泄漏。

#### 调用举例:

```
status = clReleaseKernel(kernel);
status = clReleaseProgram(program);
status = clReleaseMemObject(buffer);
status = clReleaseCommandQueue(command_queue);
status = clReleaseContext(context);
```

3 代码举例 16

## 3 代码举例

```
#include <CL/cl.h>
#include <stdio.h>
#define NWITEMS 512
// 一个kernel代码,举例。
const char *source =
        "__kernel void memset( __global uint *dst ) \n"
        "{ \n"
        " dst[get_global_id(0)] = get_global_id(0); \n"
        "} \n";
int main(int argc, char ** argv)
// 1. 获取平台
cl_platform_id platform;
clGetPlatformIDs( 1, &platform, NULL );
// 2. 获取设备.
cl_device_id device;
clGetDeviceIDs( platform, CL_DEVICE_TYPE_GPU,
                1,
               &device,
               NULL);
// 3. 创建context
cl_context context = clCreateContext( NULL,
                                      1,
                                     &device,
                                     NULL, NULL, NULL);
// 4.创建comand queue
cl_command_queue queue = clCreateCommandQueue( context,
```

3 代码举例 17

```
device,
                                               O, NULL);
// 4. 读入kernel代码, 创建kernel, 创建buffer
cl_program program = clCreateProgramWithSource( context,
                                                1,
                                                &source,
                                                NULL, NULL);
clBuildProgram( program, 1, &device, NULL, NULL, NULL );
cl_kernel kernel = clCreateKernel( program, "memset", NULL );
cl_mem buffer = clCreateBuffer( context,
                                CL_MEM_WRITE_ONLY,
                                NWITEMS * sizeof(cl_uint),
                                NULL, NULL);
// 6. 启动kernel.
size_t global_work_size = NWITEMS;
clSetKernelArg(kernel, 0, sizeof(buffer), (void*) &buffer);
clEnqueueNDRangeKernel( queue,
                        kernel,
                        1,
                        NULL,
                        &global_work_size,
                        NULL, O, NULL, NULL);
clFinish( queue );
// 7. 读取结果
cl_uint *ptr;
ptr = (cl_uint *) clEnqueueMapBuffer( queue,
                                      buffer,
                                      CL_TRUE,
                                      CL_MAP_READ,
```

# 4 关于执行模型 (execution model)

如之前所述,执行模型可以分为两部分: kernel和host program两部分。其中kernel和实际计算设备相对应。

在配置kernel时,需要配置一个context对象。

context中的command\_queue对象传递给device需要经过以下几个过程:

- 1. 入队 (queued)
- 2. 传递 (submitted)
- 3. 就绪(ready)命令被存放在device的work-pool中,准备被调度
- 4. 运行(running)与该命令相关联的work-groups会执行该命令